

Análisis de Usuarios de una Plataforma de Streaming

Informe Final — Proyecto Integrador, Minería de Datos I

1. Contexto y objetivo

Este informe resume el análisis de un dataset de usuarios de una plataforma de streaming, provisto por la cátedra, aplicando el pipeline de Minería de Datos I: inspección, calidad de datos, preparación, análisis exploratorio y reducción de dimensionalidad (PCA). El objetivo fue construir un análisis reproducible, con decisiones de preparación justificadas por evidencia observada y trazabilidad completa del proceso, no un modelo predictivo.

2. Dataset y calidad inicial

El dataset original (*streaming_users_dirty.json*) contiene 8.160 registros y 8 columnas; cada fila representa un usuario (plan de suscripción, edad, país, género favorito, consumo mensual, tickets de soporte, último ingreso). La inspección inicial detectó: 160 *user_id* duplicados, categorías inconsistentes en 3 variables categóricas (mayúsculas/minúsculas, abreviaturas, tildes y espacios ocultos) y valores imposibles fuera de cualquier rango plausible (edades negativas o de 150 años, minutos de consumo negativos o de 99.999/50.000, hasta 150 tickets de soporte).

3. Decisiones de limpieza y preparación

- Duplicados eliminados por *user_id* → 8.000 registros finales.
- Categorías normalizadas con mapas de equivalencia, verificando que no se generaran nulos nuevos.
- Valores imposibles convertidos a NaN (no eliminados ni imputados sin evidencia).
- Diagnóstico del mecanismo de falta por magnitud: *monthly_watch_time_mins* resultó MAR (10.7% de falta en Premium vs. 1.1% en Básico); el resto se trató como MCAR.
- Imputación diferenciada: mediana global o por grupo según el mecanismo, moda para la categórica. *last_login_date* no se imputó: una fecha de actividad inventada distorsiona más que dejarla vacía.

Paso	Descripción	Retención (%)
0	Dataset original	100.00
1	Eliminación de duplicados	98.04
2	Normalización de categóricas	98.04
3	Corrección de valores imposibles (rango)	98.04
4	Tratamiento de valores imposibles (outliers)	98.04
5	Imputación diferenciada	98.04

Log ETL completo: *logs/pipeline_log.csv*.

4. Hallazgos del análisis exploratorio

- El plan de suscripción organiza el consumo: mediana de 553 min (Básico) a 1.127 min (Premium) — relación clara y ordenada.
- Los tickets de soporte ($r \approx -0.0016$) y la edad ($r \approx 0$ dentro de cada plan) **no** explican el consumo: dos hipótesis intuitivas que no se sostuvieron con evidencia.
- El género favorito no varía de forma relevante por país; Comedia domina en los 7 países (16%-19%), sin preferencia regional marcada.
- Se documentó un pico anómalo en *age* = 13 (385 casos, 5 veces más que cualquier edad vecina) como limitación, sin alterar el dato.

5. Reducción de dimensionalidad (PCA)

Variables: *age*, *monthly_watch_time_mins*, *customer_support_tickets* y *subscription_plan* (codificada como ordinal, por tener un orden real). Se excluyeron *country* y *favorite_genre* (categóricas sin orden natural) y *last_login_date* (no numérica, con nulos sin imputar). **Escalamiento:** StandardScaler, obligatorio por la diferencia de varianza entre variables (*monthly_watch_time_mins* ≈ 240.000 vs. 0.6-137 en el resto). **Varianza explicada:** 60.75% en las 2 primeras componentes (35.6% + 25.2%), sin un codo marcado — reflejo de que solo dos de las cuatro variables están correlacionadas entre sí.

Interpretación: PC1 es el eje "plan + consumo" y separa con claridad los 3 planes; PC2 combina *age* y *customer_support_tickets* sin que exista una relación real entre ambas. PCA confirmó, con otra técnica, el mismo hallazgo central del EDA.

6. Conclusiones y limitaciones

El hallazgo más sólido del proyecto es que **subscription_plan** explica el nivel de consumo de los usuarios, confirmado de forma independiente en el EDA y en PCA. **Limitaciones:** el pico en *age*=13 no pudo explicarse con la información disponible; ~4% de *last_login_date* quedó sin imputar; el diagnóstico de faltantes solo se contrastó contra dos variables observadas (*subscription_plan*, *country*); y PCA se aplicó únicamente sobre variables numéricas/ordinales. El alcance de estas conclusiones está condicionado por la información disponible y por las decisiones documentadas durante el proceso.

7. Enlaces

Repositorio: https://github.com/ale250881-creator/PI_Mineria_Datos_1

Aplicación pública (Streamlit Cloud): <https://trabajo-mineria-de-datos.streamlit.app/>